

Datathon ESAN 2026 — Información Previa del Reto

Created May 22, 2026 8:58 PM

Carpeta `info_previa_para_preparanos`

Sí. La carpeta `info_previa_para_preparanos` contiene **8 imágenes** con la presentación previa del reto. Lo que se pide es esto:

Resumen Del Caso

El reto es para **FinanCrece S.A.**, una financiera peruana mediana que da créditos de consumo, créditos PYME y microcréditos a personas con poco o ningún historial bancario.

El problema central: la mora subió de **4.2% a 7.8% en 18 meses**, es decir, **+3.6 puntos porcentuales**. Sus modelos actuales, basados en regresión logística con variables sociodemográficas simples, ya no discriminan bien el riesgo en segmentos nuevos no bancarizados.

La propuesta esperada es construir un **modelo avanzado de machine learning para scoring crediticio**.

Pregunta Central

El reto pregunta:

¿Qué variables y técnicas permiten predecir si un solicitante incurrirá en mora en los próximos 90 días, y cómo traducir esa predicción en una política crediticia accionable?

Eso implica 4 cosas:

1. Identificar qué variables predicen mejor el incumplimiento.

2. Comparar algoritmos y elegir uno balanceando desempeño y explicabilidad.
3. Segmentar la cartera por nivel de riesgo.
4. Definir un umbral o bandas de score que minimicen pérdidas sin excluir buenos clientes.

Dataset

Según las láminas:

Elemento	Valor
Registros totales	50,000
Train	40,000
Test	10,000
Periodo	2022-2024
Variable objetivo	default_90d
Target	1 = mora >90 días
Distribución	78% buenos / 22% morosos
Total	18 variables
Observación	default_90d existe solo en train

Variables mostradas

Variable	Descripción
edad	Edad del solicitante
ingreso_mensual	Ingreso neto mensual declarado
score_buro	Puntaje de buró externo
dias_mora_prev	Máximos días de mora en créditos previos
ratio_endeudamiento	Deuda total / ingreso mensual
tipo_empleo	Dependiente / independiente
zona_geografica	Lima / Norte / Sur / Centro / Oriente

Variable	Descripción
<code>canal_captacion</code>	Presencial / App / Web / Asesor
<code>defaultt_90d</code>	Target binario, solo train

Nulos intencionales

Hay nulos intencionales en:

- `score_buro`
- `ingreso_mensual`
- `dias_mora_prev`

Y el tratamiento de esos nulos es parte del reto.

Entregables

Hay **3 entregables obligatorios**:

1. Notebook de análisis

Debe incluir:

- EDA: distribuciones, correlaciones, desbalance.
- Preprocesamiento: imputación, encoding, escalado.
- Mínimo 2 modelos con algoritmos distintos.
- Métricas: AUC-ROC, KS, Gini, F1-Score.
- SHAP o feature importance.

2. Presentación ejecutiva

Máximo: **10 slides**

Debe incluir:

- Resumen del problema y enfoque.

- Hallazgos principales del EDA.
- Comparativa de modelos y justificación del modelo final.
- Propuesta de política crediticia con 3 bandas de riesgo.
- Estimación del impacto en negocio.

3. Archivo de predicciones **.CSV**

Debe tener:

Columna	Descripción
<code>id_cliente</code>	Identificador del cliente
<code>prob_default</code>	Probabilidad de default

Reglas:

- `prob_default` entre 0 y 1.
- Un registro por cliente del test.
- Sin nulos ni duplicados.

Criterios De Evaluación

Puntaje total: **100 puntos**.

Criterio	Puntos	Qué evalúan
Calidad del modelo predictivo	30	AUC-ROC, KS, Gini, precisión, comparación de al menos 2 algoritmos
Interpretabilidad	25	Variables importantes, SHAP/feature importance, explicación al negocio
Impacto en negocio	25	Reducción de mora, optimización de portafolio, política crediticia propuesta
Presentación oral final	20	Claridad, narrativa, dominio del tema, respuestas al jurado

Dato importante: solo los **top 7 equipos** clasifican a la exposición final.

Restricciones

- Se puede usar Python, R y Power BI.
- Python permitido: pandas, scikit-learn, XGBoost, SHAP, matplotlib, etc.
- R permitido: tidymodels, caret, ggplot2, pROC, etc.
- Sin acceso a internet durante el evento.
- Hay 3 puntos de descarga de librerías habilitados.
- Solo se pueden usar variables del dataset provisto.
- No se permiten datos externos.
- El modelo final debe explicarse en términos de negocio.
- Incluir al menos una visualización de desempeño: curva ROC o Lorenz.
- Tiempo de entrenamiento del modelo final: máximo 10 minutos en equipo estándar.
- Equipos de 4 a 5 miembros multidisciplinarios.

Qué Significa Para Nuestra Estrategia

Esto cambia el enfoque de tus documentos: **no es churn, es riesgo crediticio / default a 90 días**.

La métrica no parece ser una sola, sino una combinación evaluada por jurado: **AUC-ROC, KS, Gini, precisión y F1**. El CSV pide probabilidad (`prob_default`), así que debemos producir un buen ranking de riesgo, no solo clase 0/1.

La solución ganadora no será solo “modelo con AUC alto”. Debe terminar en una **política crediticia de 3 bandas**, por ejemplo:

Banda	Acción
Bajo riesgo	Aprobar
Riesgo medio	Aprobar con límite menor / evaluación adicional
Alto riesgo	Rechazar o pedir garantías / documentación adicional

Dudas Abiertas

Faltan algunos detalles que habrá que confirmar cuando entreguen el dataset real:

- Nombre exacto del archivo train/test.
 - Nombre exacto de la columna ID, aunque el CSV pide `id_cliente`.
 - Si el test viene separado o dentro del mismo archivo.
 - Formato exacto/nombre requerido del CSV.
 - Si hay una métrica oculta para ranking o solo evaluación por jurado.
 - Lista completa de las 18 variables.
-

Mi Lectura Honesta

Mi lectura honesta: el reto está bastante claro. Lo más importante será preparar un pipeline rápido, explicable y orientado a negocio, no un experimento enorme.

Aquí gana una solución limpia con:

- AUC/KS/Gini sólidos.
- SHAP.
- Bandas de riesgo.
- Impacto financiero creíble.